

12/09/2024

סיווג צילומי רנטגן

פרויקט קורס הדמיה רפואית

מרצה: ד"ר אייל בן יצחק

מגישות: יעל יפת ת.ז. 038769428

קציעה יצחק ת.ז. 301111696

תוכן עניינים

2	הכנת הנתונים.....
2	הנתונים.....
2	סטנדרטיזציה של פורמט ומימדי התמונה.....
3	ארטיפקטים.....
3	עיבוד התמונות כולל הטיפול בארטיפקטים השונים.....
4	אוגמנטציה (Augmentation).....
5	חלוקה לקבוצות.....
5	בחירת המודל.....
6	ResNet.....
6	DenseNet.....
7	VGG16.....
7	הרצת המודל.....
8	ארכיטקטורת מודל - שכבות המודל.....
8	איזון קטגוריות, מנגנוני עצירה ואופטימיזציה.....
9	הערכת המודל.....
10	כיוון פרמטרים.....
11	תוצאות המודל.....
13	הסברתיות למודל- Grad-CAM.....
14	סיכום.....
14	ביבליוגרפיה.....

הכנת הנתונים

הנתונים

251 תמונות צילומי רנטגן חזה, מתויות ל 3 קבוצות ממוספרות. בקבוצה 1 – 70 תמונות, בקבוצה 2 – 70 תמונות, בקבוצה 3 – 111 תמונות, ניתוח של נתוני האימון מציג חוסר איזון משמעותי כאשר כ-60% מהתמונות מרוכזות בקטגוריה 3.

חוסר איזון כזה עלול להשפיע לרעה על ביצועי המודל בכמה אופנים:

- הטיה: המודל עלול "ללמוד" להעדיף את הקטגוריה הדומיננטית (קטגוריה 3) ולהתקשות בזיהוי נכון של תמונות מקטגוריות אחרות.
- דיוק מופחת: הקטגוריות עם פחות דוגמאות עשויות להיות מיוצגות בצורה לא מספקת, מה שיוביל לירידה בדיוק הסיווג עבורן.
- יכולת הכללה מוגבלת: המודל עלול להתקשות בהכללה על נתונים חדשים, במיוחד עבור הקטגוריות הנדירות, שכן הוא יהיה פחות "חשוף" אליהן במהלך האימון.

כדי לטפל בבעיה זו, החלטנו ליישם טכניקת משקולות. גישה זו מעניקה משקל גבוה יותר לדוגמאות מהקטגוריות הקטנות יותר, ומאפשרת למודל "לשים לב" אליהן יותר במהלך האימון. ציפינו כי שיטה זו תסייע להפחית את ההטיה, לשפר את הדיוק עבור כל הקטגוריות, ולהגביר את יכולת ההכללה של המודל.

סטנדרטיזציה של פורמט ומימדי התמונה

במהלך ניתוח הנתונים, זיהינו כי התמונות מגיעות במגוון פורמטים כמו JPEG, PNG, ו-JPG, כאשר כל אחד מהם מתאפיין במאפייני דחיסה, עומק צבע, ומאפיינים טכניים שונים. בנוסף, הבחנו בשונות גדולה בממדי התמונות, בטווח רחב של רזולוציות ומשקלי קבצים הנעים מ-KB163 עד ל-MB6.

שונות זו בפורמטים, גדלים ומשקלים עלולה להשפיע על ביצועי המודל, יתכנו הבדלים באיכות העיבוד של תמונות שונות ועלול להיווצר אתגר בסטנדרטיזציה של הקלט.

על מנת להתמודד עם השונות קבענו גודל אחיד של 224x224 פיקסלים לכל התמונות תוך שמירה על היחס המקורי, למניעת עיוותים בתמונה. הבחירה בגודל זה נבעה מהצורך בתאימות למודלים נפוצים של רשתות CNN כמו VGG, RESNET. ביצוע שינוי גודל של תמונה באמצעות הפונקציה cv2.resize ב-OpenCV עם אינטרפולציה מסוג INTER_CUBIC מספק רמה גבוהה של איכות, במיוחד כאשר מגדילים תמונה.


תהליך זה של סטנדרטיזציה בפורמט ובגודל התמונה חשוב בהכנת הנתונים, ותרם משמעותית לאיכות מערך הנתונים הסופי המשמש לאימון ולבדיקת מודל.

ארטיפקטים


ארטיפקטים בתמונות רנטגן עלולים להסתיר או לעוות תכונות קריטיות, מה שעלול להוביל לטעויות בסיווג רפואי. התייחסות לארטיפקטים בעיבוד תמונה מסייעת בשיפור הדיוק והאמינות של המודל.

זיהנו ארטיפקטים בתיקיות התמונות :

- Grid Artifacts : קווים או דפוסים הנוצרים משימוש לא נכון ברשת המונעת פיזורים בצילום רנטגן ומשפיעים על זיהוי מדויק של מבנים אנטומיים.



- Metal Artifacts ארטיפקטים של מתכת : נגרמים מנוכחות חפצי מתכת בגוף המטופל.



- Motion Artifacts ארטיפקטים של תנועה: נגרמים מתנועת המטופל במהלך הצילום.

- Noise רעשים : נגרמים מגורמים שונים כמו קרינת רקע או רגישות גבוהה מדי של הגלאי.

עיבוד התמונות כולל הטיפול בארטיפקטים השונים

- נוכחות ארטיפקטים מצריכה שלבי עיבוד מקדים, שימוש בטכניקות עיבוד תמונה יכולות לסייע בהפחתת השפעת הארטיפקטים ולשפר את איכות התמונה והסיווג.
- CLAHE היא טכניקת שיפור ניגודיות מתקדמת בתמונות המציעה יתרונות על פני השוואת היסטוגרמה רגילה. CLAHE משפרת את הניגודיות בתמונות על ידי חלוקה לבלוקים, השוואת היסטוגרמה מקומית, והגבלת ניגודיות למניעת רעש. היתרונות כוללים שיפור ניגודיות מקומית, הפחתת רעשים, ושמירה על פרטים עדינים. טכניקת CLAHE יעילה במיוחד בתמונות רפואיות כמו רנטגן, שבהן יש צורך בשיפור ניגודיות באזורים שונים תוך שמירה על פרטים. clipLimit=2.0, tileGridSize=16, 16
- החלקת התמונה: שימוש בפילטר גאוסיאני (GaussianBlur) להפחתת רעש ולהחלקת התמונה.
- עיבוד מקדים עם preprocess_input עבור מודל VGG הפונקציה preprocess_input של Keras מתאימה את התמונות למודל VGG על ידי המרת צבעים מ-RGB ל-BGR, מכיוון שמודל ה-VGG אומן במקור על

תמונות ב-BGR. חיסור ערכים ממוצעים [123.68, 116.779, 103.939] מהערוצים, ושמירה על הערכים בטווח [0, 255]. שימוש בפונקציה מבטיח שהקלט יתאים למאפייני מאגר האימון המקורי (ImageNet), מה שמוביל לביצועים אופטימליים.

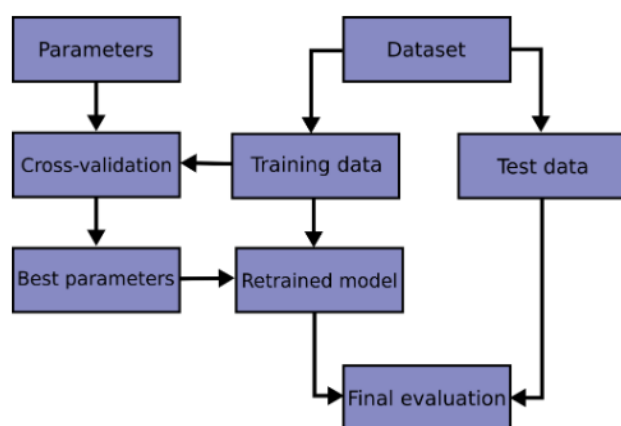
אוגמנטציה (Augmentation)

הגדלת הנתונים טכניקה חשובה מאוד בשיפור ביצועי מודלים. הגדלת המגוון של נתוני האימון מאפשרת למודל ללמוד תכונות רבות יותר ומורכבות יותר של הנתונים, מה שמוביל לשיפור בדיוק ההחלטות שלו. מניעת למידה יתר: על ידי הגדלת כמות הנתונים, המודל פחות נוטה להתאים עצמו לרעש בנתוני האימון, ובכך מונע למידה יתר overfitting. שיפור בהכללה: מודל מאומן על מערך נתונים מגוון יותר מסוגל להכליל טוב יותר נתונים שלא ראה בעבר. עמידות לרעש: מודלים מאומנים על נתונים עם רעש אקראי נוטים להיות עמידים יותר לרעש בנתוני הבדיקה.

יצרנו תמונות חדשות על ידי ביצוע שינויים קלים בתמונות המקוריות כדי למנוע שינוי קליני בתמונות. סוגי אוגמנטציה שביצענו:

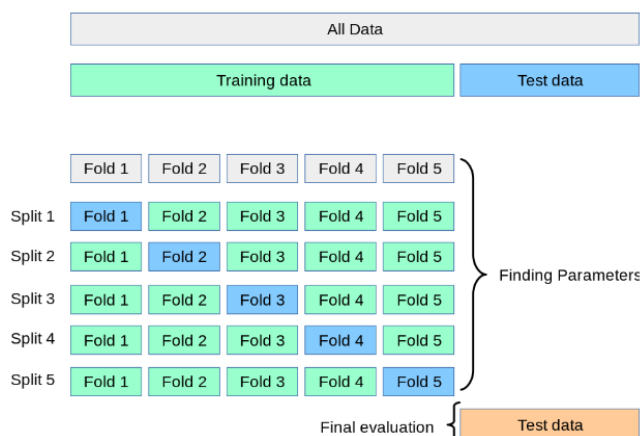
- הזזה אופקית, מזיז את התמונה ימינה או שמאלה עד 10% מרוחב התמונה מדמה שינויים קלים במיקום המטופל.
 - הזזה אנכית, מזיז את התמונה למעלה או למטה עד 10% מגובה התמונה מחקה הבדלים בגובה המיקום של המטופל.
 - זום, מגדיל או מקטין את התמונה עד 10% מחקה שינויים במרחק בין המטופל למכשיר הרנטגן.
 - סיבובים בזוויות קטנות, מחקה שינויים בתנוחת המטופל.
- בעוד שהיפוך היא טכניקה נפוצה בהגדלת נתונים לתמונות רגילות, בתמונות רנטגן של חזה היפוך יכול לשנות את המשמעות האנטומית של הצילום לכן נמנענו מלהשתמש בה. לסיכום, אוגמנטציה יכולה לעזור למודל לשפר את הביצועים שלו במצבים שבהם התמונות אינן מושלמות או מכילות רעשים טבעיים כתוצאה ממכשור ההדמיה או תנאי הצילום. אוגמנטציה היא טכניקה לשיפור ביצועי מודלים על ידי הגדלה מלאכותית של מגוון נתוני האימון באמצעות שינויים קלים בתמונות המקוריות, כגון הזזות, זום וסיבובים קטנים, תוך שמירה על המשמעות הקלינית, במטרה לשפר את יכולת ההכללה של המודל ולמנוע למידת יתר.

חלוקה לקבוצות



K-Fold Cross-Validation זו טכניקה יעילה כאשר כמות הנתונים קטנה יחסית והיא מאפשרת הערכה יציבה יותר של ביצועי המודל. זיהוי overfitting - על ידי בדיקת ביצועים על מספר חלקים שונים של הנתונים. מניעת הטיות- חלוקה פשוטה של הנתונים למערכי אימון ובדיקה עלולה לגרום להטיות אם יש הבדלים משמעותיים בין החלקים השונים של הנתונים. על ידי וידוא שכל דוגמה נכללת גם באימון וגם בבדיקה בחלוקות השונות נמנעים מהטיות אלו.

בשיטה זו הנתונים מחולקים ל-k תתי-קבוצות. המודל מאומן k פעמים, בכל פעם על k-1 קבוצות ונבדק על הקבוצה הנותרת. בחרנו להשתמש בחלוקה ל 3 קבוצות בגלל גודל הנתונים הקטן.



יישמו את StratifiedKFold שהיא טכניקה חשובה כאשר עוסקים בבעיות סיווג עם מחלקות לא מאוזנות. המטרה של StratifiedKFold היא להבטיח שהיחס בין המחלקות בכל קפל (fold) יהיה זהה ליחס במערך הנתונים המקורי, הוא שומר על ייצוג מאוזן של כל המחלקות בכל קפל, ובכך מפחית את הסיכון להטיה בתוצאות שנובעת מחלוקה לא מאוזנת של הנתונים. חלקנו את הנתונים ל 80% נתוני אימון - מתוכם 20% ולידציה, 20% בדיקה.

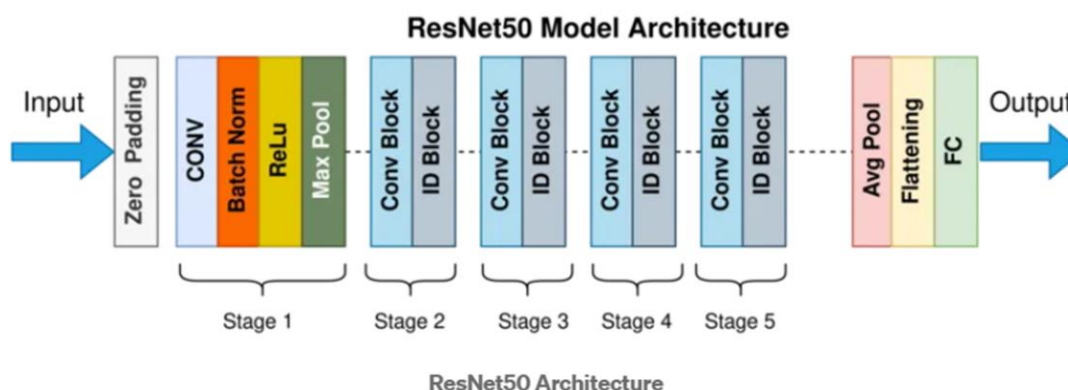
בחירת המודל

לסווג צילומי רנטגן, בחרנו להשתמש במודלים מתקדמים של למידה עמוקה המאומנים על מאגר תמונות. מודלים אלו מאפשרים לנו לזהות דפוסים מורכבים בצילומי הרנטגן ולסווג אותם בהתאם. האתגר המרכזי הוא כאשר יש מעט נתונים זמינים, אימון מודל CNN מאפס מציב אתגרים משמעותיים. הסיבה העיקרית היא שרשתות אלו דורשות כמויות גדולות של נתונים כדי ללמוד מאפיינים מורכבים ולהגיע לביצועים טובים. לכן בחרנו להשתמש ברשתות מאומנות מראש (pre-train models).

בנוסף לרשתות שיורחבו מטה, בחנו מספר ארכיטקטורות נוספות. בדקנו רשת קונבולוציונית (CNN) ורשת MobileNet שתוכננה במיוחד ליישומים ניידים.

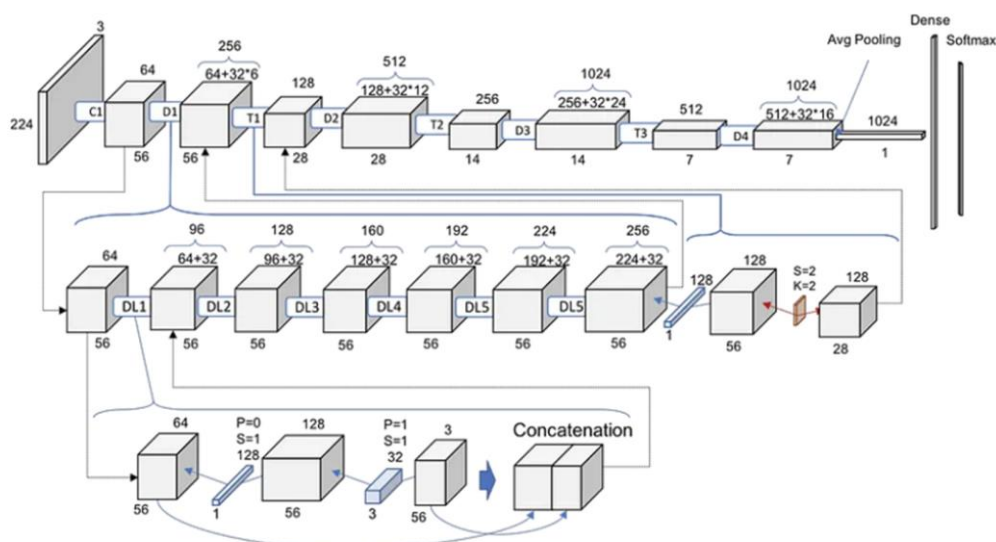
ResNet50

ResNet- Residual Networks: רשתות אלו משתמשות בשכבות residual layers כדי להעמיק את הרשת מבלי לסבול מבעיות של דעיכת גרדיאנטים. הן נפוצות מאוד בזיהוי תמונות רפואיות בשל יכולתן להתמודד עם תמונות מורכבות.




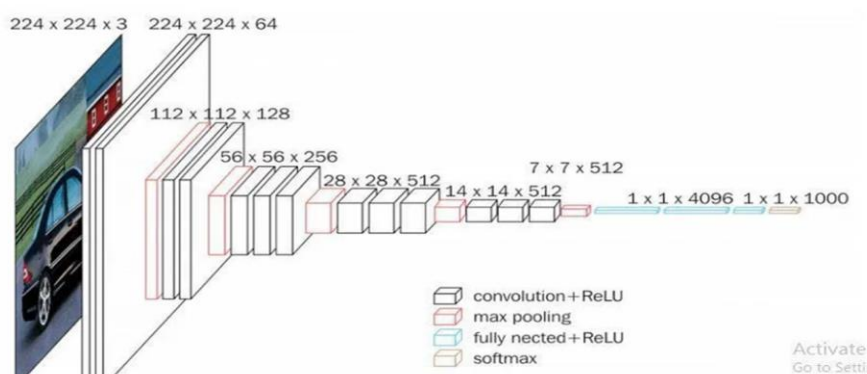
DenseNet121

DenseNet- Densely Connected Convolutional Networks: רשתות אלו מחברות כל שכבה לכל השכבות הקודמות, מה שמאפשר זרימה טובה יותר של מידע וגרדיאנטים דרך הרשת. הן יעילות במיוחד בסיווג תמונות רפואיות.



VGG16

VGG16- Visual Geometry Group: רשתות אלו משתמשות בשכבות קונבולוציה רבות עם פילטרים קטנים (3x3). הן פשוטות יחסית אך יעילות מאוד בזיהוי תבניות בתמונות רפואיות.



הרצת המודל

Transfer Learning היא טכניקת המאפשרת להעביר ידע שנצבר ממשימה אחת למשימה אחרת, קשורה או דומה. במקום לאמן מודל מאפס על נתונים חדשים, טכניקה זו משתמשת במודל שכבר אומן על משימה דומה, ובכך מאפשרת חיסכון משמעותי בזמן ובמשאבי חישוב. התהליך כולל: בחירת מודל בסיס מאומן אשר אומן על מערך נתונים גדול, הסרת השכבות האחרונות של המודל המיועדות לסיווג, והוספת שכבות חדשות המותאמות למשימה החדשה. מקפידים את השכבות של המודל המקורי כדי לשמר את הידע הכללי שנצבר ומונעים מהמשקולות בשכבות אלו להתעדכן במהלך האימון החדש, מאמנים רק את השכבות החדשות על הנתונים של המשימה החדשה.

Fine-tuning מאפשרת להתאים מודלים שאומנו מראש על מאגרי נתונים גדולים למשימות ספציפיות יותר. בתהליך זה, מודל קיים עובר אימון נוסף על מאגר נתונים קטן וממוקד, המותאם למטרה הספציפית. היתרון המרכזי של fine-tuning הוא היכולת לנצל את הידע הכללי שנרכש במהלך האימון המקורי, תוך התאמה מדויקת יותר לצרכים הייחודיים של המשימה החדשה. ניתן לבצע fine-tuning במספר אופנים, החל מעדכון כל הפרמטרים של המודל ועד לשינוי שכבות ספציפיות בלבד, כאשר הבחירה תלויה במורכבות המשימה ובמשאבים הזמינים.

שלבנו ביצוע של Transfer Learning על המודלים המצוינים ולאחר מכן ביצענו fine-tuning, בחרנו באימון 20 השכבות האחרונות מהשכבות המוקפאות ואימנו אותן כדי לשפר את הביצועים.

שיטה זו משלבת את היתרונות של שתי הטכניקות, כאשר כל שלב תורם באופן ייחודי לשיפור ביצועי המודל הסופי.

ארכיטקטורת מודל - שכבות המודל

- **GlobalAveragePooling2D**: היא שכבה בארכיטקטורות של רשתות נוירונים המבצעת הפחתת מימד (dimensionality reduction) שבה מחשבים את הממוצע של כל הערוצים. גישה זו מקטינה משמעותית את מספר הפרמטרים ברשת, ומפחיתה את הסיכון ל-overfitting ומשפר את הכללת המודל על נתונים חדשים.
- **Dense עם kernel_regularizer L2**: רגולריזציה L2 למשקולות השכבה, עוזר למניעת overfitting על ידי הענשת משקולות גדולות, הפרמטר 0.01 קובע את עוצמת הרגולריזציה.
- **Dropout**: מונע Overfitting. הערך שנבחר 0.7, מכבה באופן אקראי 70% מהנוירונים בכל צעד אימון ומאלץ את המודל ללמוד תכונות חזקות ועמידות יותר ומקטין את התלות בין הנוירונים.
- **Dense שכבת הפלט עם kernel_regularizer L2**: מספר הנוירונים בשכבה זו שווה למספר הקטגוריות שהמודל צריך לסווג, כל נוירון בשכבה זו מייצג קטגוריה אחת. פונקציית softmax מפרשת את הפלט של הרשת כהתפלגות הסתברות של הקטגוריות השונות. רגולריזציה L2 למשקולות השכבה, עוזר למניעת overfitting על ידי הענשת משקולות גדולות, הפרמטר 0.01 קובע את עוצמת הרגולריזציה.

```
x = base_model.output
x = GlobalAveragePooling2D()(x)
x = Dense(1024, activation='relu', kernel_regularizer=l2(0.01))(x)
x = Dropout(0.7)(x)
predictions = Dense(num_classes, activation='softmax', kernel_regularizer=l2(0.01))(x)
```

- **פונקציית הפסד: Loss Function** פונקציית ההפסד שנבחרה היא categorical_crossentropy, המתאימה למשימות סיווג עם מספר קטגוריות (multi-class classification).
- **Metrics: accuracy**: המודל יעקוב אחרי דיוק (accuracy) במהלך האימון וההערכה.

איזון קטגוריות, מנגנוני עצירה ואופטימיזציה


- **class_weights** - מטרתו היא לחשב משקולות לקטגוריות השונות בסט הנתונים כדי להתמודד עם אי-איזון בנתוני הקטגוריות. השיטה מייחסת משקל גבוה יותר לקטגוריות הפחות שכיחות, ובכך מסייעת למודל ללמוד בצורה מאוזנת יותר ולהימנע מהטיה כלפי הקטגוריות השכיחות. התוצאה היא מילון המפרט את המשקולות המתאימות לכל קטגוריה.
- **EarlyStopping** - מנגנון המשמש לעצירת האימון של מודל כאשר אין שיפור במדד הנמדד, מטרתו למנוע overfitting ולחסוך זמן חישוב.
 1. **monitor=val_loss**: המדד לניטור, עוקב אחר ערך ה-validation loss.
 2. **Patience=5**: ממתין 5 אפוקים ללא שיפור לפני עצירת האימון.
 3. **restore_best_weights=True**: משחזר את המשקולות הטובות ביותר שנצפו במהלך האימון.

- **ReduceLROnPlateau** - קצב הלמידה, **Learning Rate** משפיע על גודל הצעדים שהמודל עושה בכל עדכון של המשקולות, מנגנון זה משפר את האימון על ידי הקטנת קצב הלמידה כאשר הביצועים מתייצבים ומאפשר למודל להתכנס לפתרון טוב יותר.
 1. `monitor=val_loss`: עוקב אחר ערך ה-`validation loss`.
 2. `Factor=0.2`: מקטין את קצב הלמידה ב-80% (כלומר, מכפיל ב-0.2) כאשר אין שיפור.
 3. `Patience=5`: ממתין 5 אפוקים ללא שיפור לפני הקטנת קצב הלמידה.
 4. `min_lr=1e-6`: קובע את קצב הלמידה המינימלי שאליו ניתן להגיע.


הערכת המודל

- השוואת **(Training Loss)** מול **(Validation Loss)**. פונקציית ההפסד של האימון משקפת את התאמת המודל לנתוני האימון, בעוד שפונקציית ההפסד של האימות מראה את יכולת הכללה של המודל לנתונים חדשים. כאשר יש פער משמעותי בין שתי הפונקציות, זה עשוי להעיד על בעיות כמו **overfitting** או **underfitting**. השוואה זו מסייעת לקבוע את מספר האפוקים האופטימלי, לבחור היפר-פרמטרים מתאימים, ולזהות את הנקודה הטובה ביותר לעצירת האימון. היא מאפשרת ליצור מודלים מדויקים יותר עם יכולת הכללה טובה יותר.
- השוואת ה-**Accuracy** של ה-**Validation** מול ה-**Training**. ה-**training accuracy** מראה כמה טוב המודל מתאים לנתוני האימון, בעוד ש-**validation accuracy** משקף את יכולתו לנבא נכון על נתונים חדשים. פער גדול בין השניים, כאשר ה-**training accuracy** גבוה משמעותית, מצביע על **overfitting**, בעוד שערכים נמוכים בשניהם עשויים להעיד על **underfitting**. אידיאלית, שני הערכים צריכים להיות גבוהים וקרובים זה לזה, מה שמעיד על מודל מאוזן עם יכולת הכללה טובה. השוואה זו מסייעת לכוון את המודל, לבחור היפר-פרמטרים מתאימים, ולקבוע מתי לעצור את האימון כדי להשיג את הביצועים
- השוואת **(Training Loss)** מול **(Validation Loss)** עבור כל FOLD. באופן כללי, ה-**Training Loss** וה-**Validation Loss** יורדים עם התקדמות האפוקים, מה שמעיד על כך שהמודל לומד ומשפר את ביצועיו. ניתן לראות שונות מסוימת בביצועים בין הקפלים השונים, מה שמצביע על כך שהתוצאות של המודל עשויות להיות רגישות לחלוקה הספציפית של הנתונים ל-Folds.


ResNet50: הערכת המודל



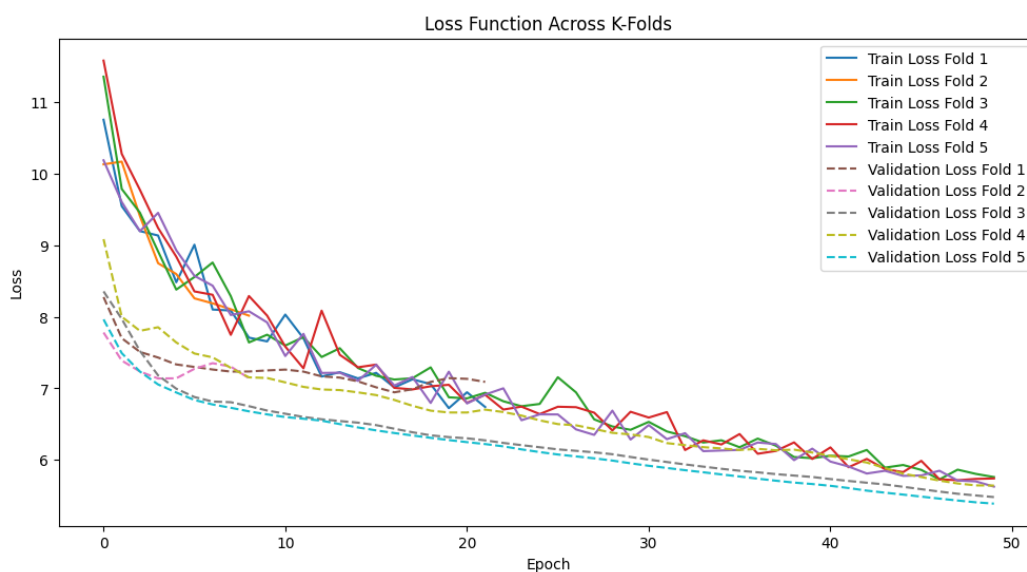
הערכת המודל: DenseNet121



הערכת המודל: VGG16



הערכת מודל VGG16 – K-Folds



כיוון פרמטרים

Learning Rate: בשלב TransferLearning הערך התחלתי נבחר 0.0001, בשלב ה Fine Tuning בחרנו בערך 0.00001. השתמשנו ב ReduceLROnPlateau כדי שקצב הלמידה ירד בצורה הדרגתית.

Batch Size: בדקנו את הערכים $64, 32 = \text{Batch Size}$ זה גרם ל Overfitting, הערך שנבחר 16.

Number of Epochs: הגדרנו 30 ראינו שהמודל לא מתכנס, העלנו את הערך בהדרגתיות ל 50, 80, 100 הערך שנבחר: 50. בחרנו להשתמש EarlyStopping כדי שהמודל יעצר כאשר אין שיפור במדד validation loss.

Dropout Rate: אחוז הנוירונים שמושמטים באופן אקראי בכל שכבה במהלך האימון כדי למנוע אימון יתר. בדקנו את הערכים 0.7, 0.5, 0.2, הערך שנבחר 0.7.


Optimizer: בחירת ה-Optimizer משפיעה על מהירות ההתכנסות ויציבות האימון, בדקנו את SGD, Adam ו AdamW. בשלב TransferLearning בחרנו AdamW, בשלב ה Fine Tuning הביצועים של Adam היו טובים יותר.

תוצאות המודל

לאחר סיום האימון, בדקנו את ביצועי המודל על מערך הבדיקה ע"י המדדים הבאים:

- Accuracy**: מוגדר כיחס בין מספר התחזיות הנכונות לסך כל התחזיות.
- Precision**: האחוז של התצפיות שסווגו כחיוביות שהיו אכן חיוביות. ז"א, מתוך כל התמונות שהמודל חזה שמשוייכות למחלקה מסוימת, כמה מהן היו שייכות למחלקה הזו באמת.
- Recall**: האחוז של התצפיות החיוביות האמיתיות שסווגו כחיוביות. ז"א, מתוך כל התמונות ששייכות למחלקה מסוימת, כמה מהן זוהו נכון על ידי המודל.
- F1-Score**: מדד זה הוא ההרמוני ממוצע של Precision ו-Recall, ומספק אינדיקציה כוללת על הביצועים של המודל.
- מטריצת בלבול (**Confusion Matrix**): מציגה באופן ויזואלי את הביצועים של המודל, מראה כמה פעמים המודל צדק וכמה פעמים טעה עבור כל קטגוריה.

תוצאות מודל ResNet50:



תוצאות המודל DenseNet121

Accuracy	Precision	Recall	F1 Score
0.8824	0.9176	0.8824	0.8864



תוצאות המודל VGG16

Accuracy	Precision	Recall	F1 Score
0.9804	0.9817	0.9804	0.9804




הסברתיות למודל - Grad-CAM

Grad-CAM-Gradient-weighted Class Activation Mapping היא טכניקה המיועדת להבהיר את תהליכי קבלת ההחלטות של רשתות נוירונים קונבולוציוניות (CNNs). שיטה זו מאפשרת לנו לחשוף באופן ויזואלי את האזורים בתמונה שהשפיעו על החלטת הסיווג של המודל. היא מאפשרת הצצה לתוך "הקופסה השחורה" של רשתות נוירונים ולהבין טוב יותר את האופן שבו הן מקבלות החלטות, מסייעת באיתור בעיות או הטיית, ומספקת כלי חשוב לשיפור ואופטימיזציה של מודלים.


הטכניקה פועלת על ידי ניתוח הגרדיאנטים הזורמים לשכבה הקונבולוציונית האחרונה של ה-CNN. היא מחשבת ממוצע של גרדיאנטים אלה עבור כל ערוץ תכונות, ומשתמשת בממוצעים אלה כמשקולות לשקלול מפות התכונות. התוצאה היא מפת חום המדגישה את האזורים החשובים ביותר בתמונה מבחינת המודל.

יישמו טכניקה זו במודל VGG16 :


דוגמא להסברתיות לקטגוריה 1



דוגמא להסברתיות לקטגוריה 2



דוגמא להסברתיות לקטגוריה 3



סיכום

פרויקט זה התמקד בפיתוח מודל למידה עמוקה לסיווג תמונות רנטגן חזה, במטרה לסייע באבחון מהיר ומדויק של מחלות ריאה שונות. התבססנו על מאגר נתונים של 251 תמונות מתויגות, בדקנו 3 מודלים שונים עליהם יישמנו ארכיטקטורת CNN מבוססת VGG16, ResNet-50, DenseNet121 עם טכניקות של Transfer Learning, Fine Tuning ואופטימיזציה של היפר-פרמטרים. המודל הסופי הציג ביצועים מרשימים, עם דיוק כולל של 98% על סט הבדיקה, רגישות גבוהה במיוחד לזיהוי דלקת ריאות, ומדד 1F ממוצע של 0.98. התמודדנו עם אתגרים כמו חוסר איזון בנתונים ו-overfitting באמצעות שימוש בטכניקות מתקדמות של עיבוד נתונים ורגולריזציה. התוצאות מצביעות על פוטנציאל גבוה לשימוש המודל כמערכת תמיכה בהחלטות קליניות, אם כי נדרש מחקר נוסף לבחינת ביצועיו בסביבה קלינית אמיתית לשיפור הדיוק.

ביבליוגרפיה

- <https://chatgpt.com/c/66e12509-cc10-8008-8baf-8e711d6d27de>
- <https://www.perplexity.ai/search/title-u05e0-u05ea-u05e0-u05d9-IMYLaJExQNyoHQpgOhdLtQ>
- <https://medium.com/@mygreatlearning/everything-you-need-to-know-about-vgg16-7315defb5918>
- <https://towardsdatascience.com/understanding-and-visualizing-densenets-7f688092391a>
- <https://medium.com/@nitishkundu1993/exploring-resnet50-an-in-depth-look-at-the-model-architecture-and-code-implementation-d8d8fa67e46f>
- https://scikit-learn.org/stable/modules/cross_validation.html

